Отчет об анализе данных химических соединений и построении модели для предсказания наиболее эффективного сочетания параметров для создания лекарственных препаратов

План отчета:

1. Анализ данных. 1
2. Регрессия для IC50 4
3. Регрессия для CC50 6
4. Регрессия для SI 7
5. Классификация: превышает ли значение IC50 медианное значение выборки IC50 8
6. Классификация: превышает ли значение CC50 медианное значение выборки CC50 10
7. Классификация: превышает ли значение SI медианное значение выборки SI 12
8. Классификация: превышает ли значение SI значение 8 14
9. Выводы 15

1. Анализ данных.

Исходные данные имеют 214 колонок и 1001 строку. Из них: 3 колонки с целевыми показателями (IC50, CC50, SI), остальные колонки-признаки. Большое количество признаков затруднит обучение модели и увеличит риск ее переобучения, поэтому целью работы над данными помимо их чистоты будет и снижение размерности массива.

Были проделаны следующие шаги по выявлению зависимостей и очистке данных:

1. Обнаружены незначительные пропуски, которые были удалены в дальнейшей работе (3 строки).
2. Построена матрица корреляций с визуализаций только сильной связи (коэффициент более 0.8). Выявлено множество признаков с высокой корреляцией, из которых оставили только одну колонку. Таким образом количество признаков сократилось до 151 + 3 колонки с целевыми показателями.

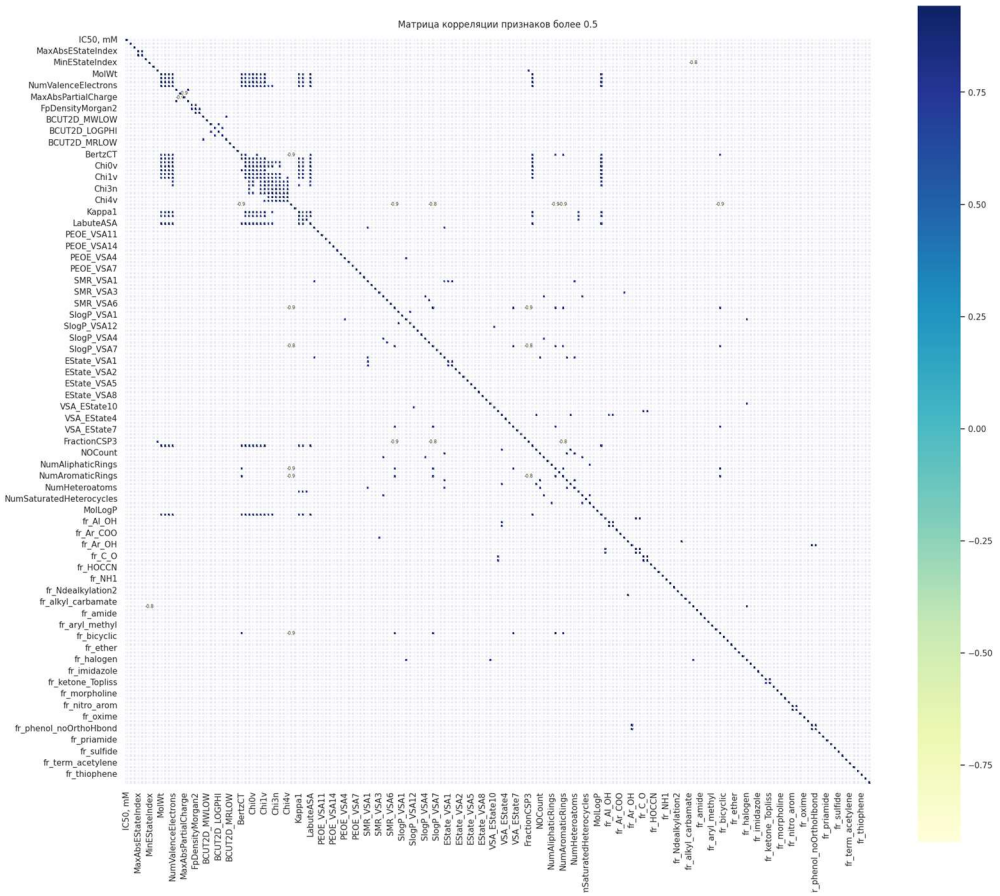

3. Сделан анализ данных по числовым признакам: целевые переменные IC50 , CC50 и SI скошены и имеют правостороннюю асимметрию (среднее больше медианы) и требуют логарифмирования перед обучением модели.

	IC50, mM	CC50, mM	SI
count	998.000000	998.000000	998.000000
mean	221.118757	586.668414	72.650005
std	400.510657	642.016454	685.504279
min	0.003517	0.700808	0.011489
25%	12.491340	99.999036	1.457233
50%	45.992006	408.793314	3.856410
75%	224.408630	891.770961	16.525000
max	4128.529377	4538.976189	15620.600000

4. Для снижения размерности данных объединяем функциональные группы признаков и создаем новые объединенные признаки:

- колонки (fr_) объединены по семантике:

sum_fr_aromatic (из 5 признаков)
sum_fr_acidic (из 2 признаков)
sum_fr_basic (из 4 признаков)
sum_fr_hbd (из 3 признаков)
sum_fr_hba (из 5 признаков)
sum_fr_halogen (из 2 признаков)
sum_fr_sulfur (из 6 признаков)
sum_fr_nitro (из 1 признаков)
sum_fr_rings (из 7 признаков)

- все функциональные группы составлены в общую характеристику, для понимания сложная молекула или простая:

sum_all_fr (из 69 признаков)
active_fr (из 69 признаков)

- группа признаков Estate электронного состояния заменена на статистические параметры состояния каждого электрона в молекуле из 9 признаков:

mean_estate
max_estate
min_estate
range_estate
std_estate

- все площади молекулы (43 признака) объедены в 3 признака VSA (общая площадь поверхности молекулы, среднее свойство молекулы и разнообразие свойств молекулы):

sum_vsa
mean_vsa
std_vsa

- данные из 6 признаков по гидрофобности объедены в 2 признака общая гидрофобность и средняя гидрофобность молекулы: sum_slogp, mean_slogp

Использованные в объединении признаков колонки удалены.
В итоге количество признаков сократилось до 37 + 3 колонки целевых переменных.

5. В массиве были отделены данные-признаки и целевые переменные.
6. Т.к. данные имеют разную размерность проведено их нормирование для обнаружения линейной связи с помощью StandardScaler.
7. Для снижения размерности и анализа связи применен PCA (метод главных компонент)

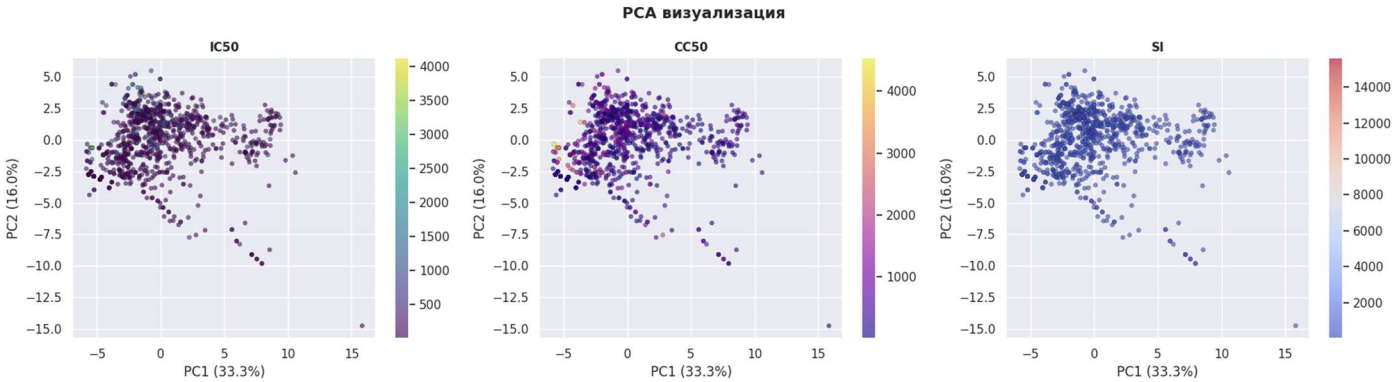

Доля объясненной дисперсии главными компонентами недостаточна и визуализации данных не показывает линейной зависимости. т.е. данные имеют сложную нелинейную структуру и имеют выбросы хорошо заметные на графике.

8. Для нормирования применен RobustScaler, который не чувствителен к выбросам и может работать с нелинейными данными, .
9. Далее использован метод UMAP (графовой интерпретации данных), с тестовыми гиперпараметры. Для тестирования выбраны:

   n_neighbors_options = [20, 25, 30, 40, 50, 70, 100]

   min_dist_options = [0.3, 0.5, 0.8, 0.9]

   n_components_options = [2, 3, 4, 5, 6, 7]

   Метриками оценки UMAP выбраны:

   - trustworthiness (сохранение структуры данных после снижения размерности);

   - KNN accuracy (точность разбиения на классы при разном пространстве данных, но не изменяя других параметров метода).

   На основе полученных результатов оптимальные гиперпараметры:

   n_components = 5, n_neighbors = 50, min_dist = 0.3
10. Создан массив с UMAP компонентами с выбранными гиперпараметрами и визуализируем данные для первых 3-х компонент:

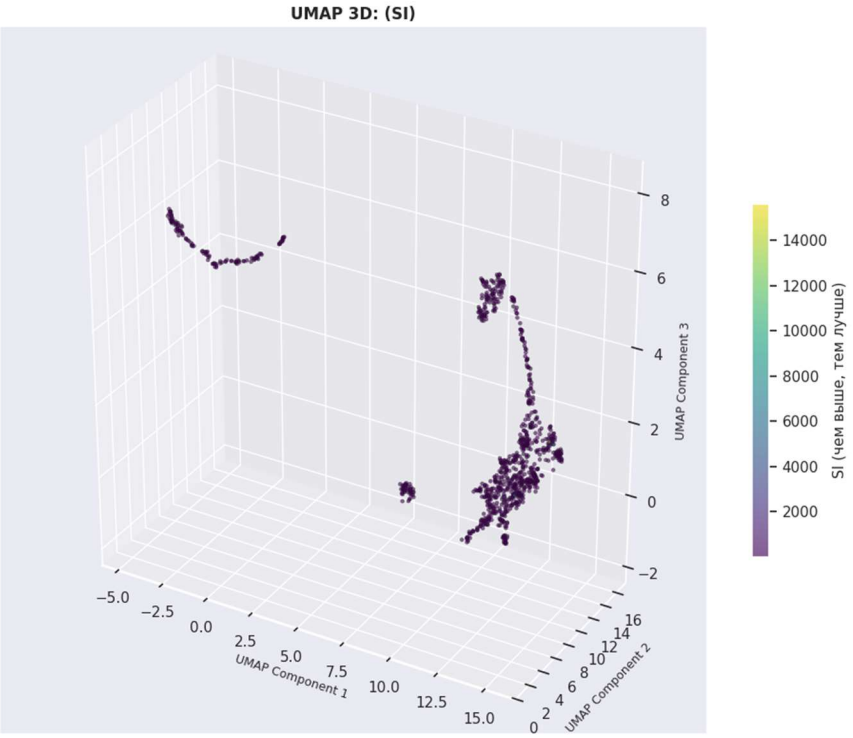

Структура данных сложная, основная часть сконцентрирована в ядре и имеется длинный хвост выбросов. Для предсказания будем настраивать сложные нелинейные модели.

11. Полученные признаки сохранили в файл для дальней работы и обучения моделей. Файл 1 - только UMAP признаки и целевые переменные, файл 2 – UMAP признаки, 42 очищенных признака и целевые переменные.

2. Регрессия для IC50

Использованы данные, полученные после EDA. Выбрана только одна целевая переменная (IC50), для которой построена модель регрессии.

1. Выборка разделена на обучающую и валидационную для обоих наборов данных (только UMAP признаки и все признаки вкл UMAP
2. Целевая переменная логарифмирована на обучающей и валидационной выборках.
3. Признаки стандартизированы через RobustScaler, чтобы обучить модели метода опорных векторов, ближайших соседей, но и не помешать методам градиентного спуска и случайного леса.
4. Создан список моделей для тестирования с базовыми параметрами. Метрикой для анализа качества модели выбрана R^2 (коэффициент детерминации), т.к. он показывает величину объясненной моделью дисперсии без интерпретации абсолютных значений и подходит для первоначального выбора модели.
5. Для подтверждения предположения по анализу данных об использовании линейных моделей был проведен пробный запуск обучения линейных моделей. Модели Ridge и Lasso показали отрицательный R^2 (-0.09 и -0.18 соответственно), что говорит о невозможности применения линейных моделей (они предсказывают хуже, чем предсказание просто среднего значения). Дальнейшая работа продолжена только с нелинейными методами.
6. Тестирование и поиск лучшей модели сделан на 2-х вариантах данных: все данные+UMAP и только UMAP. Решающая метрика R^2.

Модели на всех признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 10, 'min_samples_leaf': 4, 'min_samples_split': 3, 'n_estimators': 230}	R^2 (исходная шкала): 0.2534 MAE: 205.6206 RMSE: 454.1266 CV R^2: 0.4180	Средние результаты
Gradient Boosting	{'learning_rate': 0.02, 'max_depth': 4, 'n_estimators': 250, 'subsample': 0.8}	R^2 (исходная шкала): 0.2988 MAE: 200.7490 RMSE: 440.1158 CV R^2: 0.4172	Вторая модель для дальнейшей оптимизации гиперпараметров
XGBoost	{'learning_rate': 0.01, 'max_depth': 5, 'n_estimators': 300}	R^2 (исходная шкала): 0.2669 MAE: 201.9440 RMSE: 449.9908 CV R^2: 0.4042	Средние результаты
LightGBM	{'learning_rate': 0.05, 'n_estimators': 100, 'num_leaves': 11}	R^2 (исходная шкала): 0.2734 MAE: 200.7039 RMSE: 447.9890 CV R^2: 0.4022	Средние результаты
SVM	{'C': 10, 'epsilon': 0.5, 'gamma': 0.1}	R^2 (исходная шкала): 0.3292 MAE: 197.5657 RMSE: 430.4436 CV R^2: 0.3382	Лучшая модель по результатам предварительного подбора. Будет участвовать в дальнейшем анализе
KNN	{'metric': 'manhattan', 'n_neighbors': 18, 'weights': 'distance'}	R^2 (исходная шкала): 0.2111 MAE: 202.4150 RMSE: 466.8117 CV R^2: 0.3340	Наименьший результат из нелинейных моделей

Модели на UMAP признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 10, 'min_samples_leaf': 4, 'min_samples_split': 3, 'n_estimators': 300}	R^2 (исходная шкала): 0.0612 MAE: 220.7274 RMSE: 509.2226 CV R^2: 0.2776	В целом результаты только на UMAP признаках значительно ниже, чем на всех данных после EDA. Поэтому для дальнейшего обучения будем использовать данные после EDA совместно с UMAP признаками
Gradient Boosting	{'learning_rate': 0.02, 'max_depth': 5, 'n_estimators': 220, 'subsample': 0.8}	R^2 (исходная шкала): 0.0266 MAE: 228.2567 RMSE: 518.5208 CV R^2: 0.2686	
XGBoost	Лучшие параметры: {'learning_rate': 0.01, 'max_depth': 5, 'n_estimators': 300}	R^2 (исходная шкала): 0.0122 MAE: 228.3130 RMSE: 522.3631 CV R^2: 0.2575	
LightGBM	{'learning_rate': 0.1, 'n_estimators': 120, 'num_leaves': 7}	R^2 (исходная шкала): 0.0601 MAE: 224.5901 RMSE: 509.5217 CV R^2: 0.2716	
SVM	{'C': 10, 'epsilon': 0.3, 'gamma': 'auto'}	R^2 (исходная шкала): 0.2576 MAE: 209.4885 RMSE: 452.8430 CV R^2: 0.2648	
KNN	{'metric': 'manhattan', 'n_neighbors': 18, 'weights': 'distance'}	R^2 (исходная шкала): 0.0537 MAE: 220.9861 RMSE: 511.2566 CV R^2: 0.2869	

7. Результаты подбора гиперпараметров для SVM и GradientBoosting:

SVM: - модель склонна к переобучению как видим по параметру CV R^2 и на тестовой выборке показывает хуже результат, чем при подборе парметров. Поэтому оставляем гиперпараметры из первого поиска.

```
Лучшие параметры SVR: {'gamma': 0.2, 'epsilon': 0.8, 'C': 3}
SVR
Тест R²: 0.2115
MAE: 210.28
RMSE: 466.70
CV R²: 0.3764
```

GradientBoosting: гиперпараметры дали улучшение, поэтому сохраняем модель

```
Лучшие параметры GB: {'subsample': 0.8, 'n_estimators': 300, 'min_samples_split': 10, 'min_samples_leaf': 4, 'max_depth': 4, 'learning_rate': 0.02}
Gradient boosting
Тест R²: 0.3412
MAE: 198.53
RMSE: 426.58
```

8. Создан ансамбль из 2-х лучших моделей и дал следующие результаты:

```
Ансамбль
Тест R²: 0.3341
MAE: 197.19
RMSE: 428.87
```

9. В качестве финальной модели оставлен модель Gradient Boosting с параметрами: {'subsample': 0.8, 'n_estimators': 300, 'min_samples_split': 10, 'min_samples_leaf': 4, 'max_depth': 4, 'learning_rate': 0.02}, которая показала Тест R^2: 0.3412, MAE: 198.53, RMSE: 426.58. 34,1% объясненной дисперсии удовлетворительный результат для использования модели в качестве первичного скрининга соединений.
10. Модель для предсказания и модель для нормализации сохранены в сессионное хранилище и сделана проверка открытия модели и компонентов.

3. Регрессия для CC50

Шаги по созданию модели и предсказаний аналогичны предыдущей регрессии IC50. Отмечены только отличающиеся моменты и выводы.

1. Модели на всех признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 18, 'min_samples_leaf': 4, 'min_samples_split': 5, 'n_estimators': 300}	R^2 (исходная шкала): 0.2682 MAE: 332.6845 RMSE: 587.1386 CV R^2: 0.3937	Лучшие результаты, модель использована для дальнейшей оптимизации
Gradient Boosting	{'learning_rate': 0.02, 'max_depth': 5, 'n_estimators': 220, 'subsample': 0.6}	R^2 (исходная шкала): 0.2431 MAE: 355.7486 RMSE: 597.1156 CV R^2: 0.3518	Средние результаты
XGBoost	{'learning_rate': 0.01, 'max_depth': 5, 'n_estimators': 300}	R^2 (исходная шкала): 0.1992 MAE: 375.2625 RMSE: 614.2114 CV R^2: 0.3588	Низкие из представленных
LightGBM	{'learning_rate': 0.05, 'n_estimators': 140, 'num_leaves': 11}	R^2 (исходная шкала): 0.2402 MAE: 358.7710 RMSE: 598.2839 CV R^2: 0.4013	Средние результаты
SVM	{'C': 10, 'epsilon': 0.5, 'gamma': 0.1}	R^2 (исходная шкала): 0.2613 MAE: 369.6837 RMSE: 589.9014 CV R^2: 0.3438	Вторая модель для оптимизации
KNN	{'metric': 'manhattan', 'n_neighbors': 12, 'weights': 'distance'}	R^2 (исходная шкала): 0.2461 MAE: 332.7680 RMSE: 595.9378 CV R^2: 0.3102	Средние результаты

Модели на UMAP признаках не показали достаточно хороших результатов и не использованы для построения регрессии

2. Результаты подбора гиперпараметров для SVM и Random Forest :

SVM: - подбор дал улучшение результата

```
Лучшие параметры SVR: {'gamma': 0.2, 'epsilon': 0.3, 'C': 3}
SVR
Тест R²: 0.3181
MAE: 351.75
RMSE: 566.75
CV R²: 0.3622
```

Random Forest: гиперпараметры не дали улучшение (модель склонна к переобучению как видим по параметру CV R^2 и на тестовой выборке показывает хуже результат, чем при подборе параметров), поэтому сохраняем модель из первого подбора

```
Лучшие параметры RF: {'n_estimators': 500, 'min_samples_split': 15, 'min_samples_leaf': 6, 'max_features': 0.3, 'max_depth': 25, 'bootstrap': False}
Random Forest
Тест R²: 0.2542
MAE: 335.12
RMSE: 592.74
CV R²: 0.4054
```

3. Создан ансамбль из 2-х лучших моделей и дал следующие результаты. Они не стали лучше:

```
Ансамбль
Тест R²: 0.2889
MAE: 343.03
RMSE: 578.80
```

4. В качестве финальной модели оставлен модель SVM с параметрами: (C=3, epsilon=0.3, gamma=0.2), которая показала Тест R^2: 0.3181, MAE: 351.75, RMSE: 566.75. 31,8% объясненной дисперсии удовлетворительный результат для использования модели в качестве первичного скрининга соединений.

5. Модель для предсказания и модель для нормализации сохранены в сессионное хранилище и сделана проверка открытия модели и компонентов.

4. Регрессия для SI

Шаги по созданию модели и предсказаний аналогичны предыдущей регрессии IC50. Отмечены только отличающиеся моменты и выводы.

1. Модели на обоих сетах данных (все данные и только UMAP признаки) для регрессии показали результаты R^2 близким к 0 или ниже нуля, что не позволяет их использовать для дальнейшей оптимизации. В связи с широким диапазоном значений целевой переменной SI, даже после логарифмирования диапазон слишком широк для достоверного предсказания.

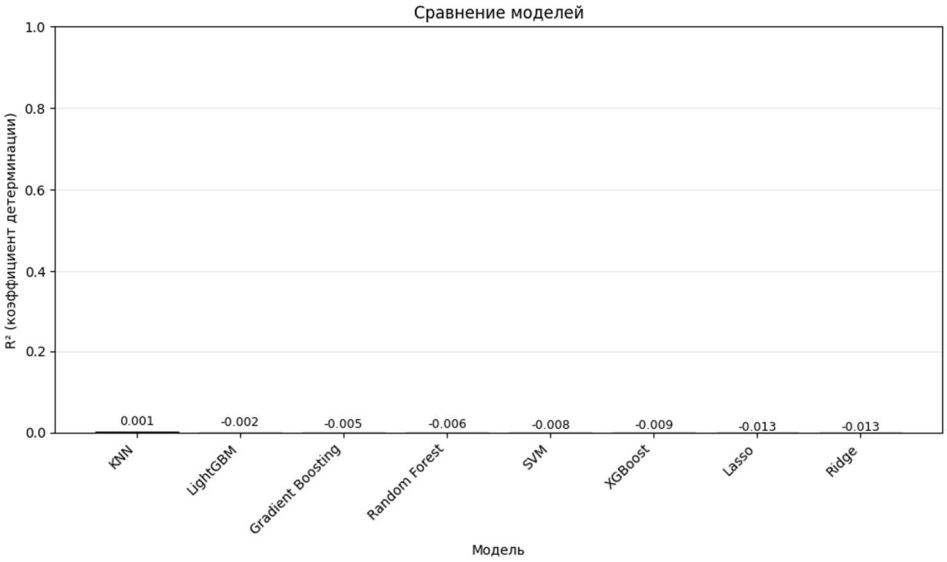

2. Был использован дополнительный алгоритм HuberRegressor, который должен быть менее чувствителен к выбросам. Но, к сожалению, он также показал неудовлетворительный результат.
3. Была произведена очистка данных по максимальным выбросам. Удалено 5% самых больших отклонений. После очистки данных опять произведено обучение модели, результат не улучшился:

```
Huber
Тест R²: -0.0176
MAE: 188.74
RMSE: 1433.79
```

4. Модель регрессии для SI удовлетворяющего качества построить не удалось. Для ее построения необходимо:
   - пересмотреть признаки изначального датасета с учетом профессиональной специфики и их взаимосвязи, которая может быть не очевидна статистическими методами,
   - увеличить объем выборки до 7 тыс образцов (7 тыс=10*210/0.3)
   - перейти к модели бинарной классификации (реализовано в данной работе)

5. Классификация: превышает ли значение IC50 медианное значение выборки IC50

Для создания предсказания используются нелинейные модели. Перед использованием оставили только одну целевую переменную IC50.

1. Выборка разделена на обучающую и валидационную для обоих наборов данных (только UMAP признаки и все признаки вкл UMAP).
2. Размечены классы больше/меньше медианы IC50 на основе медианы обучающей выборки:
   1 (True) когда IC50 > медианы (слабый препарат)
   0 (False) когда IC50 ≤ медианы (сильнодействующий препарат)
3. Проверен баланс классов. Классы в тестовой выборке почти соотвествуют классам в обучающей выборке (обучающая 50% на 50% (как и ожидалось), тестовая 52,5% на 47,5%. Балансировку классов производить не нужно.
4. Признаки стандартизированы через RobustScaler, чтобы обучить модели метода опорных векторов, ближайших соседей, но и не помешать методам градиентного спуска и случайного леса.
5. Создан параметр кросс-валидации для использования GridSearchCV и опредены модели и гиперпараметры для поиска: Random Forest, Gradient Boosting, SVC с RBF и KNeighborsClassifier и более продвинутые модели: XGBoost и LightGBM.
   Тестирование и поиск лучшей модели сделан на 2-х вариантах данных: все данные+UMAP и только UMAP. Метрики для выбора: Accuracy, ROC-AUC, F1-Score. ROC-AUC является приоритетной метрикой, т.к. химические образцы важнее правильно ранжировать и не пропустить активные соединения.

Модели на всех признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 20, 'min_samples_leaf': 2, 'min_samples_split': 20, 'n_estimators': 350}	Accuracy: 0.675, ROC-AUC: 0.790, F1-Score: 0.660	Модель показала лучшие результаты по ROC-AUC и будет использована для дальнейшей оптимизации
Gradient Boosting	{'learning_rate': 0.01, 'max_depth': 4, 'n_estimators': 200, 'subsample': 0.6}.	Accuracy: 0.670, ROC-AUC: 0.761, F1-Score: 0.649	Результаты выше среднего, но хуже лучшем модели
XGBoost	{'learning_rate': 0.01, 'max_depth': 5, 'n_estimators': 250}.	Accuracy: 0.660, ROC-AUC: 0.769, F1-Score: 0.634	Результаты выше среднего, но хуже лучшем модели
LightGBM	{'learning_rate': 0.1, 'n_estimators': 100, 'num_leaves': 10}.	Accuracy: 0.710, ROC-AUC: 0.780, F1-Score: 0.678.	Лучшие результаты по Accuracy и f1, но ниже по ROC_AUC, вторая модель для дальнейшей оптимизации
SVM	{'C': 1, 'gamma': 0.1, 'kernel': 'rbf'}.	Accuracy: 0.665, ROC-AUC: 0.745, F1-Score: 0.646	Результаты ниже среднего из выбранных моделей
KNN	{'metric': 'manhattan', 'n_neighbors': 5, 'weights': 'uniform'}.	Accuracy: 0.660, ROC-AUC: 0.731, F1-Score: 0.642.	Из выбранных моделей самые низкие результаты

Модели на UMAP признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 20, 'min_samples_leaf': 5, 'min_samples_split': 5, 'n_estimators': 350}	Accuracy: 0.610, ROC-AUC: 0.700, F1-Score: 0.589	В целом результаты только на UMAP признаках значительно ниже, чем на всех данных после EDA. Поэтому для дальнейшего обучения будем использовать данные после EDA совместно с UMAP признаками
Gradient Boosting	{'learning_rate': 0.01, 'max_depth': 4, 'n_estimators': 200, 'subsample': 1.0}	Accuracy: 0.595, ROC-AUC: 0.664, F1-Score: 0.589	
XGBoost	{'learning_rate': 0.01, 'max_depth': 5, 'n_estimators': 200}	Accuracy: 0.610, ROC-AUC: 0.678, F1-Score: 0.576	
LightGBM	{'learning_rate': 0.1, 'n_estimators': 150, 'num_leaves': 10}	Accuracy: 0.620, ROC-AUC: 0.711, F1-Score: 0.600	
SVM	{'C': 50, 'gamma': 0.1, 'kernel': 'rbf'}	Accuracy: 0.605, ROC-AUC: 0.691, F1-Score: 0.591	
KNN	{'metric': 'manhattan', 'n_neighbors': 15, 'weights': 'distance'}	Accuracy: 0.660, ROC-AUC: 0.743, F1-Score: 0.649	

6. Сделан углубленный поиск гиперпараметров через RandomizedSearchCV для двух моделей RandomForecast и Gradient Boosting:
   RandomForecast результаты оптимизации:

```
Best params: {'n_estimators': 1200, 'min_samples_split': 10, 'min_samples_leaf': 1, 'max_features': 0.3, 'max_depth': 20, 'class_weight': 'balanced_subsample'}
Accuracy: 0.7500
Test ROC-AUC: 0.8444
```

   LightGBM результаты оптимизации:

```
Fitting 5 folds for each of 50 candidates, totalling 250 fits
Best params: {'subsample': 0.8, 'num_leaves': 10, 'n_estimators': 100, 'min_child_samples': 30, 'max_depth': 10, 'learning_rate': 0.1}
Accuracy:  0.7200
ROC-AUC:   0.7922
F1-Score:  0.6989
```

7. Был реализован ансамбль из 2-х моделей. Результат по метрикам не улучшился (Accuracy: 0.7050, ROC-AUC: 0.7985, F1-Score: 0.6811), скорее всего из-за схожести моделей (ошибаются в одинаковых местах).
8. Выбрана модель по лучшей площади под ROC-кривой – RandomForecast с параметрами: class_weight=None, max_depth=15, max_features=0.3, min_samples_leaf=4, min_samples_split=2, n_estimators=300, random_state=42
9. Модель, медиана для меток и модель для нормализации сохранены в сессионное хранилище и сделана проверка открытия модели и компонентов.

6. Классификация: превышает ли значение CC50 медианное значение выборки CC50

Шаги по созданию модели и предсказаний аналогичны предыдущей классификации. Отмечены только отличающиеся моменты и выводы.

1. Проверен баланс классов. Обучающая 50% на 50% (как и ожидалось), тестовая 54% на 46%. Балансировку классов производить не нужно.
2. Модели на всех признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 20, 'min_samples_leaf': 2, 'min_samples_split': 15, 'n_estimators': 300}	Accuracy: 0.750 ROC-AUC: 0.838 F1-Score: 0.762	Модель показала лучшие результаты по ROC-AUC и будет использована для дальнейшей оптимизации
Gradient Boosting	{'learning_rate': 0.01, 'max_depth': 4, 'n_estimators': 300, 'subsample': 0.6}	Accuracy: 0.745 ROC-AUC: 0.833 F1-Score: 0.763	Результаты выше среднего и почти равны с RandomForecast.
XGBoost	{'learning_rate': 0.05, 'max_depth': 5, 'n_estimators': 200}	Accuracy: 0.745 ROC-AUC: 0.834 F1-Score: 0.751	Результаты выше среднего, но хуже лучшем модели
LightGBM	{'learning_rate': 0.05, 'n_estimators': 100, 'num_leaves': 15}	Accuracy: 0.720 ROC-AUC: 0.823 F1-Score: 0.728	Результаты чуть выше среднего, не подходит для дальнейшей оптимизации
SVM	{'C': 10, 'gamma': 0.1, 'kernel': 'rbf'}	Accuracy: 0.685 ROC-AUC: 0.771 F1-Score: 0.704	Из выбранных моделей самые низкие результаты
KNN	{'metric': 'manhattan', 'n_neighbors': 11, 'weights': 'distance'}	Accuracy: 0.740 ROC-AUC: 0.807 F1-Score: 0.748	Результаты ниже среднего из выбранных моделей

Модели на UMAP признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 30, 'min_samples_leaf': 2, 'min_samples_split': 10, 'n_estimators': 200}	Accuracy: 0.680 ROC-AUC: 0.758 F1-Score: 0.692	В целом результаты только на UMAP признаках значительно ниже, чем на всех данных после EDA. Поэтому для дальнейшего обучения будем использовать
Gradient Boosting	{'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 200, 'subsample': 0.6}	Accuracy: 0.665 ROC-AUC: 0.747 F1-Score: 0.679	
XGBoost	{'learning_rate': 0.05, 'max_depth': 7, 'n_estimators': 200}	Accuracy: 0.660 ROC-AUC: 0.772 F1-Score: 0.663	

LightGBM	{'learning_rate': 0.05, 'n_estimators': 100, 'num_leaves': 15}	Accuracy: 0.670 ROC-AUC: 0.746 F1-Score: 0.683	данные после EDA совместно с UMAP признаками
SVM	{'C': 1, 'gamma': 1, 'kernel': 'rbf'}	Accuracy: 0.625 ROC-AUC: 0.733 F1-Score: 0.634	
KNN	{'metric': 'manhattan', 'n_neighbors': 15, 'weights': 'distance'}	Accuracy: 0.680 ROC-AUC: 0.776 F1-Score: 0.677	

3. Сделан углубленный поиск гиперпараметров для двух моделей RandomForecast и Gradient Boosting:
   RandomForecast результаты оптимизации:

```
Best params: {'n_estimators': 1200, 'min_samples_split': 10, 'min_samples_leaf': 1, 'max_features': 0.3, 'max_depth': 20, 'class_weight': 'balanced_subsample'}
Accuracy: 0.7500
Test ROC-AUC: 0.8444
F1-Score:  0.7596
```

   Gradient Boosting результаты оптимизации:

```
Best params: {'subsample': 0.6, 'n_estimators': 300, 'min_samples_split': 2, 'min_samples_leaf': 3, 'max_features': 'log2', 'max_depth': 4, 'learning_rate': 0.03}
Accuracy:  0.7300
ROC-AUC:   0.8211
F1-Score:  0.7429
```

4. Выбрана модель по лучшей площади под ROC-кривой – RandomForecast с параметрами: n_estimators': 1200, 'min_samples_split': 10, 'min_samples_leaf': 1, 'max_features': 0.3, 'max_depth': 20, 'class_weight': 'balanced_subsample'
5. Модель, медиана для меток и модель для нормализации сохранены в сессионное хранилище и сделана проверка открытия модели и компонентов. Метрики составили: Accuracy: 0.7500, Test ROC-AUC: 0.8444, F1-Score: 0.7596.

7. Классификация: превышает ли значение SI медианное значение выборки SI

Шаги по созданию модели и предсказаний аналогичны предыдущей классификации. Отмечены только отличающиеся моменты и выводы.

1. Проверен баланс классов. Обучающая 50% на 50% (как и ожидалось), тестовая 50% на 50%. Балансировку классов производить не нужно.
2. Модели на всех признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 10, 'min_samples_leaf': 5, 'min_samples_split': 20, 'n_estimators': 200}	Accuracy: 0.710 ROC-AUC: 0.748 F1-Score: 0.663	Результаты по всем моделям средние, но наилучший из представленных моделей дал Gradient Boosting. Он будет использован для дальнейшей оптимизации
Gradient Boosting	{'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 300, 'subsample': 0.6}	Accuracy: 0.735 ROC-AUC: 0.753 F1-Score: 0.686	
XGBoost	{'learning_rate': 0.05, 'max_depth': 2, 'n_estimators': 250}	Accuracy: 0.710 ROC-AUC: 0.739 F1-Score: 0.663	
LightGBM	{'learning_rate': 0.05, 'n_estimators': 100, 'num_leaves': 10}	Accuracy: 0.675 ROC-AUC: 0.721 F1-Score: 0.615	
SVM	{'C': 1, 'gamma': 0.1, 'kernel': 'rbf'}	Accuracy: 0.705 ROC-AUC: 0.723 F1-Score: 0.642	
KNN	{'metric': 'manhattan', 'n_neighbors': 11, 'weights': 'uniform'}	Accuracy: 0.620 ROC-AUC: 0.669 F1-Score: 0.568	

Модели на UMAP признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 10, 'min_samples_leaf': 2, 'min_samples_split': 20, 'n_estimators': 300}	Accuracy: 0.630 ROC-AUC: 0.654 F1-Score: 0.560	В целом результаты только на UMAP признаках значительно ниже, чем на всех данных после EDA. Поэтому для дальнейшего обучения будем использовать данные после EDA совместно с UMAP признаками
Gradient Boosting	{'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 200, 'subsample': 0.6}	Accuracy: 0.650 ROC-AUC: 0.651 F1-Score: 0.568	
XGBoost	{'learning_rate': 0.01, 'max_depth': 2, 'n_estimators': 200}	Accuracy: 0.645 ROC-AUC: 0.638 F1-Score: 0.559	
LightGBM	{'learning_rate': 0.05, 'n_estimators': 150, 'num_leaves': 10}	Accuracy: 0.620 ROC-AUC: 0.610 F1-Score: 0.558	

SVM	{'C': 10, 'gamma': 'auto', 'kernel': 'rbf'}	Accuracy: 0.665 ROC-AUC: 0.689 F1-Score: 0.608	
KNN	{'metric': 'euclidean', 'n_neighbors': 15, 'weights': 'distance'}	Accuracy: 0.650 ROC-AUC: 0.662 F1-Score: 0.593	

3. Добавлена еще одна модель на базовых параметрах: CatBoostClassifier. Accuracy: 0.7200, ROC-AUC: 0.7517, F1-Score: 0.6854
4. Сделан углубленный поиск гиперпараметров для двух моделей Gradient Boosting и CatBoost: Gradient Boosting результаты оптимизации:

```
Fitting 5 folds for each of 100 candidates, totalling 500 fits
Best params: {'subsample': 0.6, 'n_estimators': 250, 'min_samples_split': 10, 'min_samples_leaf': 4, 'max_features': 'log2', 'max_depth': 6, 'learning_rate': 0.007}
Accuracy:  0.7100
ROC-AUC:   0.7566
F1-Score:  0.6506
```

CatBoost результаты оптимизации:

```
Best params: {'learning_rate': 0.02, 'l2_leaf_reg': 3, 'iterations': 400, 'depth': 4, 'border_count': 254, 'auto_class_weights': 'Balanced'}
Accuracy: 0.7050
ROC-AUC:  0.7554
F1-Score: 0.6550
```

5. Выбрана модель по лучшей площади под ROC-кривой – CatBoost с параметрами: iterations=500, learning_rate=0.03, depth=6, cat_features=[], random_seed=5, auto_class_weights='Balanced', verbose=0, eval_metric='AUC'). Это базовая модель, т.к. оптимизация гиперпараметров не дала прибавки в метриках.
6. Модель, медиана для меток и модель для нормализации сохранены в сессионное хранилище и сделана проверка открытия модели и компонентов. Метрики составили: Accuracy: 0.7200, ROC-AUC: 0.7517, F1-Score: 0.6854.

8. Классификация: превышает ли значение SI значение 8

Шаги по созданию модели и предсказаний аналогичны предыдущей классификации. Отмечены только отличающиеся моменты и выводы.

1. Проверен баланс классов. Обучающая 64% на 36%, тестовая 65,5% на 34,5%. Есть некоторый дисбаланс классов. Для балансировки сделан SMOTE. Миноритарный класс добавлен до мажоритарного. Дальнейшая работа идет с массивом с добавленными данными.
7. Модели на всех признаках:

Модель	Лучшие параметры	Метрики	Выводы
Random Forest	{'max_depth': 20, 'min_samples_leaf': 2, 'min_samples_split': 5, 'n_estimators': 350}	Accuracy: 0.680 ROC-AUC: 0.725 F1-Score: 0.500	Результаты по всем моделям средние, но наилучший из представленных моделей дал LightGBM. Он будет использован для дальнейшей оптимизации
Gradient Boosting	{'learning_rate': 0.05, 'max_depth': 4, 'n_estimators': 300, 'subsample': 0.8}	Accuracy: 0.665 ROC-AUC: 0.704 F1-Score: 0.472	
XGBoost	{'learning_rate': 0.05, 'max_depth': 7, 'n_estimators': 250}	Accuracy: 0.660 ROC-AUC: 0.722 F1-Score: 0.500	
LightGBM	{'learning_rate': 0.05, 'n_estimators': 150, 'num_leaves': 30}	Accuracy: 0.700 ROC-AUC: 0.741 F1-Score: 0.552	
SVM	{'C': 30, 'gamma': 'auto', 'kernel': 'rbf'}	Accuracy: 0.685 ROC-AUC: 0.704 F1-Score: 0.512	
KNN	{'metric': 'manhattan', 'n_neighbors': 5, 'weights': 'distance'}	Accuracy: 0.640 ROC-AUC: 0.686 F1-Score: 0.507	

Модели на UMAP признаках не показали значительные результаты.

8. Добавлена еще одна модель на базовых параметрах: CatBoostClassifier. Accuracy: 0.7450, ROC-AUC: 0.7429, F1-Score: 0.6331
9. Сделан углубленный поиск гиперпараметров для двух моделей LightGBM и CatBoost:
   LightGBM результаты оптимизации:

```
Fitting 5 folds for each of 50 candidates, totalling 250 fits
Best params: {'subsample': 0.8, 'num_leaves': 10, 'n_estimators': 100, 'min_child_samples': 15, 'max_depth': 10, 'learning_rate': 0.08}
Accuracy:  0.7100
ROC-AUC:   0.7409
F1-Score:  0.5797
```

   CatBoost результаты оптимизации:

```
Best params: {'random_strength': 1, 'learning_rate': 0.03, 'l2_leaf_reg': 2, 'iterations': 500, 'depth': 6, 'border_count': 128, 'auto_class_weights': 'Balanced'}
Accuracy: 0.6900
ROC-AUC:  0.7275
F1-Score: 0.5303
```

10. Выбрана модель по лучшей площади под ROC-кривой – CatBoost с параметрами: iterations=500, learning_rate=0.03, depth=6, cat_features=[], random_seed=36, auto_class_weights='Balanced', verbose=0, eval_metric='F1'). Это базовая модель, т.к. оптимизация гиперпараметров не дала прибавки в метриках.
11. Модель, медиана для меток и модель для нормализации сохранены в сессионное хранилище и сделана проверка открытия модели и компонентов. Метрики составили: Accuracy: 0.7450, ROC-AUC: 0.7429, F1-Score: 0.6331.

9. Выводы

В рамках исследования и создания моделей для предсказания целевых переменных получены удовлетворительные результаты, которые можно применить для первоначального анализа химических соединений. Возможные улучшения точности предсказаний и работы модели могут быть достигнуты путем:

1 – создания новых признаков из базы данных на основе специфических знаний химических соединений

2 – уточнения имеющихся признаков и/или добавления новых

3 – увеличения числа наблюдений до 7-10 тыс

4 – использования более продвинутых нелинейных моделей машинного обучения